

哈尔滨工业大学深圳校区

毕业论文中期报告

题 目 基于轻量化卷积神经网络与注意力机制的水下舰船声学分类研究

姓 名 陈浩宇

学 号 220210229

学 院 电子与信息工程学院

专 业 通信工程

指导教师 李维

日 期 2026年3月2日

目 录

1 课题主要研究内容及进度.....	1
1.1 课题主要研究内容.....	1
1.2 进度介绍.....	1
2 已完成的研究工作及结果.....	3
2.1 数据集构建与预处理阶段.....	3
2.2 模型架构设计与改进阶段.....	5
2.3 训练评估管线与不平衡学习策略.....	8
2.4 对比实验与消融研究执行阶段.....	10
3 后期拟完成的研究工作及进度安排.....	18
3.1 后期拟完成的研究工作.....	18
3.2 进度安排.....	18
4 存在的困难及解决方案.....	20
4.1 存在的困难.....	20
4.2 解决方案.....	20
5 论文按时完成的可能性.....	22

1 课题主要研究内容及进度

1.1 课题主要研究内容

本研究的核心目标是, 面向 AUV 等边缘计算平台, 研发一种高效、轻量化的舰船声学目标分类模型。舰船辐射噪声并非均匀的随机信号, 而是由水动力噪声、机械噪声和螺旋桨噪声等多种声源叠加而成, 各自在时频谱上表现为独特的线谱、谐波和节律性特征。传统识别方法如 LOFAR 和 DEMON 虽能捕获部分特征, 但其严重依赖专家知识进行人工特征提取, 无法满足自动化、智能化部署的需求。相比之下, 基于深度学习的方法, 特别是卷积神经网络 (CNN), 能够从数据中自动学习这些关键的声学指纹。故本研究方案将首先立足于舰船声学机理的分析, 将原始声学信号转换为富含信息的梅尔频谱图, 再以此为基础, 系统地开展后续研究。为确保更精准、更高效地捕获频谱图中的关键物理特征, 缓解 AUV 上识别准确度与计算资源消耗之间的矛盾, 本演技与又提出了一系列的轻量化 CNN 模型设计、注意力机制的融合优化、非对称卷积的探索与模型缩放策略。

1.2 进度介绍

目前, 本项目已顺利完成第一阶段与第二阶段的核心研发与实验验证任务。在数据处理层面, 针对涵盖真实海洋声学环境与多类船舶辐射噪声的 DeepShip 数据集, 完成了完整工程化多源数据预处理管线的开发。考虑到水下监听节点录音中常伴随长时间的无目标时段与复杂海洋背景干扰, 成功实现了基于均方根 (RMS) 能量的静音检测以精准截取有效声段; 针对舰船辐射噪声 (螺旋桨节律、机械线谱) 集中在低频段的物理特性, 优化了动态重叠率切分与对数 Mel 频谱图提取参数; 同时为模拟复杂水下声信道的传播畸变与航行引起的多普勒频移, 引入了涵盖波形域与混合域的数据增强机制。

在模型架构层面, 成功设计并搭建了以 MobileNetV2 反转残差块为基础的轻量化卷积神经网络 MyNet。为更精准地捕获水声频谱特征, 网络中探索融合了非对称卷积 (Asymmetric Convolution) 与多尺度混合卷积, 并完成了 SE、CBAM 等注意力机制的模块化部署。此外, 针对数据集中各类船只数据量极不平衡的痛点, 项

目开发了文件级多数投票评估机制，并引入了包含焦点损失 (Focal Loss) 与 Logit Adjustment (LA) 策略的定制化训练管线。

当前，已全面执行并完成了基础网络核心组件 (M1 至 M5 变体)、注意力部署位置深度寻优以及数据预处理策略的系统性消融实验。实验数据明确验证了最优架构 M5 (融合非对称卷积与 Stage 2/4 Pre-DW CBAM 注意力) 配合训练期先验校正 (TF 策略) 在提升分类性能与统计稳健性上的显著优势。下一步的研究重心将按计划向第三阶段推进。

后续工作将集中于进一步提升模型各项指标，探索面向 MCU 部署的模型缩放策略 (Model Scaling) 与开展基于 Grad-CAM 技术的模型可解释性可视化分析，并同步推进毕业论文的撰写与统稿。

2 已完成的研究工作及结果

2.1 水声数据集构建与预处理阶段

2.1.1 DeepShip 数据下载与介绍

DeepShip 是本次模型训练的主要数据集，其记录于真实海洋环境中，涵盖不同季节与海况条件。除船舶信号外，记录信号还包含自然背景噪声、海洋哺乳动物噪声以及其他人为活动产生的噪声。数据集累计录制时长达 47 小时 4 分钟，涵盖了 265 艘不同特征的船舶。样本被严格划分为四类主要的商用船只：油轮 (Oil Tanker)、拖船 (Tug)、客船 (Passenger Ship) 及货轮 (Cargo Ship)，极其适于训练一款通过水声信号识别船只的模型。但在真实的海洋中，货轮 (Cargo) 的数量天然就远多于客船，该数据集中各类船只间的数据量极不平衡，且每条数据长 1 分钟到 30 分钟不等，难以直接用以模型训练，需要进一步处理。

2.1.2 裁剪长数据并处理水声信号的低能量片段

由于数据集中船舶水声数据较少且单挑录音时间过长，本项目设计了 `prepare_deepship_data_5s.py` 脚本。该脚本实现了一套完整的工程化预处理管线：读取原始录音、重采样、混音 (Mix to Mono)、峰值归一化、切片，将原船舶水声文件处理成等长，多样，且在一定程度上数量更多的切片，最后将切片结果写入训练/测试列表文件。其中的核心是基于 RMS (均方根) 能量的静音检测 (Voice Activity Detection)。对每一个切出的 5 秒片段，计算其 RMS 能量值；如果该值低于预设阈值 (默认 `rms_threshold=0.005`)，则直接跳过该片段，不将其写入数据集。这一机制有效过滤了水下录音中常见的麦克风静置时段、海洋背景噪声占优的低信噪比片段，保证送入网络的每条样本都存在有效的船舶声学信号。由下图 2.1 可以明显看出效果。




图 2.1 静音检测（VAD）截断效果对比图

2.1.3 应对水声采集差异与数据不平衡的音频归一化与动态重叠切分

为了消除复杂海洋环境对声学信号采集带来的干扰，并缓解 DeepShip 数据集天然的类别极度不平衡问题，本项目在预处理阶段引入了峰值归一化与动态重叠切分机制。流程分为以下两个关键步骤：

- ① **峰值归一化** (Peak Normalization)：在切片之前，先对整段原始录音进行峰值归一化，将幅值统一缩放到 $[-1, 1]$ 区间。这一步既能消除不同录音设备或采集条件带来的绝对音量差异，又由于是峰值归一化（而非均值）而保留了各类船舶声音之间相对的能量分布关系
- ② **动态重叠率切分** (Overlapping Slices) DeepShip 数据集中，货轮 (Cargo) 与拖船 (Tug) 的数据量远多于客船 (Passenger Ship) 和油轮。传统的统一重叠切片无法改变这一长尾分布。为扩充训练集规模，并平衡各类别的数据量差异，本项目对训练集音频按类别分别设定不同的重叠率 (overlap_ratio)，步长 (stride) 按下式计算。重叠率越高，从一段音频中能切出的片段越多。测试集则不使用重叠（重叠率为 0），以保证评估客观性：

$$\text{stride} = \lfloor L_{\text{seg}} \times (1 - r_{\text{overlap}}) \rfloor \quad (1)$$

其中 L_{seg} 为目标切片长度（5 秒对应的采样点数）， r_{overlap} 为当前类别对应的重叠率。

2.1.4 声学特征工程提升：Mel 频谱图参数优化

图 2.2 展示了油轮、拖船、客船和货轮四类船舶 5 s 水声片段的对数 Mel 频谱图。四类目标均表现出明显的低频主导特征，说明船舶辐射噪声的主要能量集中于中低频范围，这与主机振动、传动系统及螺旋桨噪声的物理机理一致。在此基础上，不同类别又呈现出可区分的纹理差异：油轮低频能量连续且分布宽厚，拖船中低频区域存在更明显的窄带结构，客船包含若干跨频段的瞬态垂直条纹，而货轮则表现出较稳定的分层带状能量分布。上述现象表明，不同船舶类别在时频域中具有肉眼可见的结构差异，因此可将 Mel 频谱视为具有物理可解释性的水声目标表征，并进一步利用 CNN 对其纹理模式进行自动判别。




图 2.2 四类舰船辐射噪声的 Mel 频谱特征对比图

声学特征的提取在 preprocess.py 中完成。核心是将原始波形转换为对数 Mel 频谱图 (Log-Mel Spectrogram)，并在此基础上进一步提取一阶差分 and 二阶差分 (Delta & Delta-Delta)，最终将三者沿通道维度堆叠为 $(3, n_mels, T)$ 的三通道特征图，供网络学习动态时序特征。针对水声信号频谱集中在低频区间的物理特性（船舶螺旋桨发出的空化噪声、机械噪声主要分布在 $20\text{Hz} \sim 3000\text{Hz}$ ），对 Mel 频谱提取参数进

行了专项优化：

表 2.1 Mel 频谱图参数列举

参数	设定值	说明
n_fft	2048	较大的 FFT 窗口, 频率分辨率约 7.8 Hz/bin
n_mels	160	较高的 Mel Bank 数量, 增大纵向频率分辨率
f_min	20 Hz	尽可能捕获低频声学特征
f_max	3000 Hz	聚焦于船舶噪声频带, 排除海洋高频背景干扰
hop_length	512	约 32ms 的帧移步长

2.1.5 数据增强与正则化：SpecAugment + 背景噪声注入

为提升模型对不同水声环境的泛化能力，在 dataset.py 的 AudioDataset 类中实现了一套多层次的数据增强管线，增强按顺序在波形域（Waveform-domain）应用：

- ① **粉红噪声注入** (Pink Noise Injection)：使用 AddBackgroundNoise 类, 基于 FFT 在频域生成 $1/f$ 功率谱形状的粉红噪声（更接近真实海洋背景噪声的频率特性），并以随机的目标信噪比（10dB~30dB）叠加到原始信号上，模拟复杂水下传播信道
- ② **速度扰动** (Speed Perturbation)：SpeedPerturbation 类通过在 {0.9, 0.95, 1.0, 1.05, 1.1} 五个离散倍速中随机采样, 对音频进行变速（同时改变音调），模拟不同航速下的目标多普勒频移效应。
- ③ **混合增强** (Mosaic + Mixup)：在增强管线末端额外实现了 Audio Mosaic（将同类的 4 段音频拼接为一条样本）和 Mixup（跨类波形线性插值混叠），进一步提升了模型的边界判决鲁棒性。




图 2.3 数据增强策略（泛化能力）可视化验证图

通过图 2.3 的直观展示，证明增强管线有效模拟了水下长距离传播时的衰减和多普勒效应，提升了模型对复杂海况的鲁棒性。

2.1.6 数据集划分机制：文件级分层 K 折交叉验证

舰船辐射噪声是具有高度时序连续性的物理信号。由于预处理阶段采用了重叠

切片机制,同一艘船在同一次录音中衍生出的相邻切片,不仅包含了高度相似的目标声纹,还共享了完全相同的瞬时海洋背景噪声。如果按切片(Segment-level)随机划分,必然导致同一录音的不同切片分散在训练集与测试集中,造成数据泄露(Data Leakage),使模型评估结果虚高,失去科学意义。

针对水声录音文件总数较少且类别极不均衡的客观限制,本项目对于验证集引入了按类别进行分层(Stratified)的K折交叉验证(K=5)。该机制确保了每一折验证集中,各类船舶文件的比例与整体数据集分布保持一致。每个原始文件在完整的交叉验证周期内仅作为验证数据出现一次。此外,在数据划分结束后,系统会触发防泄漏断言(Leakage Prevention Assertion)校验,确保模型在完全未见的独立水声文件上进行客观评估。

2.2 模型架构设计与改进阶段

2.2.1 面向 AUV 边缘端部署的轻量化骨干网络设计

在实际的水下侦察与监测场景中,模型最终需要部署在算力、内存和功耗均极其受限的 AUV 边缘微控制器(MCU)上。传统的重型卷积神经网络虽然特征提取能力强,但因计算复杂度过高而无法满足水下实时监测的需求。为此,本项目的核心模型 MyNet 专门针对边缘侧约束进行了轻量化设计,其核心理念继承自 MobileNetV2:

① **深度可分离卷积**(Depthwise Separable Convolution):将标准卷积分解为一个逐深度卷积(Depthwise Conv,每个通道独立卷积)和一个 1×1 逐点卷积(Pointwise Conv),参数量与计算量均大幅减少。以标准卷积为基准,设输入特征图尺寸为 $D_F \times D_F$,输入输出通道数分别为 M, N ,卷积核尺寸为 D_K ,则两者的计算量之比为:

$$\frac{\text{DW-Separable FLOPs}}{\text{Standard FLOPs}} = \frac{D_K^2 \cdot M \cdot D_F^2 + M \cdot N \cdot D_F^2}{D_K^2 \cdot M \cdot N \cdot D_F^2} = \frac{1}{N} + \frac{1}{D_K^2} \quad (2)$$

② **反转残差瓶颈块**(Inverted Residual Block):不同于传统 ResNet 的"宽-窄-宽"瓶颈结构, MobileNetV2 采用"窄-宽-窄"的反向设计——先用 1×1 卷积将低维特征升维(Expansion),再在高维空间做深度卷积,最后用 1×1 再降回低维并接残差连接。升维比例由超参数 expand_ratio 控制:

$$\text{hidden_dim} = \lfloor \text{inp} \times t \rfloor, \quad t = \text{expand_ratio} \quad (3)$$

MyNet 的网络层级结构 (Stage) 以列表形式 [t, c, n, s, attn] 写入配置中, 每个元素分别关键参数如下表格所示:

表 2.2 层级结构关键参数解析

t	瓶颈层升维倍率 (expand_ratio)
c	该阶段输出通道数
n	重复 Block 的数量
s	首个 Block 的步长 (用于下采样)
attn	注意力类型编码

model_config 通过配置文件 YAML 动态传入, 无需改动模型代码即可切换架构

代码块 2.1 model_config 示例

```
# 以无注意力的基础配置为例 (M1/M2 使用)
CONFIG_BASE = [
    [1, 16, 1, 1, 0], # Stage 1: t=1, c=16, n=1, s=1, attn=无
    [6, 24, 2, 2, 0], # Stage 2: t=6, c=24, n=2, s=2, attn=无
    [6, 32, 3, 1, 0], # Stage 3: ...
    [6, 64, 4, 2, 0], # Stage 4
    [6, 96, 3, 1, 0], # Stage 5
    [6, 160, 3, 1, 0], # Stage 6
    [6, 320, 1, 1, 0], # Stage 7
]
```

MyNet 的主干构建循环读取此列表, 迭代实例化 InvertedResidual 块并串接为完整的 nn.Sequential:

代码块 2.2 实例化函数

```
for t, c, n, s, attn_code in model_config:
    output_channel = int(c * width_mult)
    attention_mode = attn_map.get(attn_code) # {0:None, 1:'post_dw', 2:'pre_dw', 3:'se',
    4:'freq'}
    for i in range(n):
```

```
stride = s if i == 0 else 1 # 只有每段第一个块做下采样
features.append(block(current_channels, output_channel, stride,
                      expand_ratio=t, attention_mode=attention_mode, ...))
current_channels = output_channel
```

2.2.2 适配声学频谱各向异性的非对称与多尺度卷积机制

① **非对称卷积 (AsymmetricConv)**: 水声 Mel 频谱图在频率轴 (纵向) 和时间轴 (横向) 上的纹理分布有明显的各向异性: 频率轴上表征了谐波、共振峰等结构性分布, 时间轴上则体现了转速脉动等周期性模式。为此, 引入了非对称卷积 (Asymmetric Convolution) 结构, 将 $K \times K$ 卷积分解为 $K \times 1$ 和 $1 \times K$ 两步串行卷积:

$$W_{K \times K} \approx W_{K \times 1} * W_{1 \times K} \quad (4)$$

当开启非对称卷积时, InvertedResidual 块内的深度卷积 (Depthwise Conv) 由标准 3×3 卷积替换为分解后的非对称 7×7 卷积 (即 7×1 再 1×7 组合), 在感受野不变的前提下参数量减少、同时使网络分别学习频率与时间两个轴上的独立模式。

② **多尺度混合卷积 (MixConv)** 舰船辐射噪声既包含短促的瞬态空化噪声, 也包含绵长的机械轰鸣。: MixConv 将同一深度卷积层的输入通道按三等分分别送入核尺寸为 3×3 、 5×5 、 7×7 的三路卷积中, 最终在通道维度上拼接, 实现在同一特征层内捕获不同尺度的声学纹理。

2.2.3 抑制海洋背景噪声的动态注意力过滤与部署策略

① 三种注意力模块的实现

model.py 中实现了三种可插拔的注意力模块: SE, 利用全局平均池化压缩空间信息为通道描述符, 通过 MLP 学习通道间的非线性依赖关系, 输出逐通道的重要性权重; CBAM, 按顺序串联 ChannelAttention 和 SpatialAttention 两个子模块, 通道注意力同时使用平均池化和最大池化两条路径, 空间注意力则在沿通道维度压缩后生成二维空间权重图; FrequencyAttention (频率注意力), 针对音频 Mel 频谱图设计的专用注意力, 将时间轴 (W 轴) 做全局平均池化、保留频率轴 (H 轴), 产生逐频率带的重要性权重, 使网络在频率维度上自适应聚焦。

② 基于 Stage 的动态注意力插入点设计

本研究最核心的架构创新在于, 注意力模块的插入位置 (Pre-DW 还是 Post-DW) 以

及插入阶段均可通过配置列表中的 attn 编码一键切换，无需任何代码改动。

2.3 训练评估管线与不平衡学习策略

2.3.1 通用化训练验证管线

为实现模型的快速迭代验证，本项目整个训练流程封装于 train.py 的 train() 函数中，以 YAML 配置文件路径为唯一入参，run_experiments.py 通过动态生成不同实验的 YAML 文件再调用该函数，实现了配置与代码的完全解耦。训练管线按以下顺序串联各个核心步骤：

- ① **全局随机种子固定**：为确保实验可复现性，在训练开始前统一设置所有随机源的种子，并强制 cuDNN 进入确定性模式（一定程度上以速度换稳定性）
- ② **训练集/验证集/测试集三路隔离加载**：配置同时指定三条数据列表路径，三者在整个实验生命周期中严格隔离——训练集含完整数据增强，验证集和测试集均以推理模式（train=False）初始化（关闭所有增强）
- ③ **优化器与学习率调度**：使用 AdamW 优化器，学习率调度器采用余弦退火（CosineAnnealingLR），在整个训练周期内平滑地将学习率从初始值衰减到 0：

$$\eta_t = \eta_{min} + \frac{1}{2}(\eta_{max} - \eta_{min}) \left(1 + \cos \frac{t\pi}{T_{max}} \right) \quad (5)$$

- ④ **基于 Top-K 模型保存的早停机制（Early Stopping）**：训练过程中每个 epoch 结束后，在验证集上执行文件级别评估，将当前指标（F1 或 Acc，由配置决定）与历史保存的 Top-K 模型队列对比。若优于队列中最差的模型则替换并更新队列，若连续 patience 个 epoch 未进入 Top-K 则触发早停。

训练结束后，自动回载 Top-K 中的最优模型权重，在冻结的测试集上执行一次性的最终评估并将结果写入 results.txt 文件，整个过程测试集从不参与任何模型选择决策。

2.3.2 契合真实部署与时间连续性的文件级聚合决策

音频分类的特殊挑战在于：深度学习模型是对孤立的短时切片（Segment，例如 5 秒）进行预测，但在实际 AUV 边缘端侦察中，需要对目标的一段连续伴随录音

(Recording) 做出全局身份判决。直接以切片级别的准确率衡量性能会导致指标虚高，且对噪声扰动极为敏感。本项目在 rain.py 的 run_file_level_eval() 函数和 test.py 中均实现了完整的文件级评估逻辑，其核心流程分三步：

- ① 通过路径正则解析还原文件 ID 预处理阶段生成的切片命名格式为 {录音 ID}_seg{偏移量}.wav（例如 41_seg160000.wav）。评估时逐样本解析其路径，用正则表达式剥除 _seg\d+.wav 后缀，还原出原始录音文件 ID (file_id)，将每个切片的预测结果归并到对应的文件桶中
- ② 文件级投票聚合：系统支持三种可配置的投票聚合策略

策略	说明
majority	统计该文件所有切片中各类别预测次数，取最多数类别
top_k	挑选置信度（最大 Softmax 概率）最高的前 K 个切片做多数投票
entropy	以各切片预测熵的倒数为权重，加权求和各类别概率后取 argmax

- ③ 文件级指标汇总聚合所有录音文件的投票结果后，计算文件级别的准确率、Macro Precision、Recall 和 F1，同时打印切片级（Segment-level）和文件级（File-level）两组指标，能直观观察到多数投票机制带来的性能增益。

2.3.3 处理然海洋长尾分布的多维空间类别均衡化

DeepShip 数据集存在明显的类别不平衡问题——Cargo 类和 Tug 类数量远多于 Passengership 和 Tanker 类。本项目通过以下五个方面同时入手，进行系统性的对抗。

- ① **有效样本数类别权重** (Class Weights with Effective Number of Samples)：在计算交叉熵损失的类别权重时，采用基于有效样本数 (Effective Number of Samples) 的方法，而非简单的频率倒数。该方法通过超参数 β 控制平滑程度，相比直接取倒数对极端不平衡情况更加鲁棒：

$$E_n = 1 - \beta^{n_y}, \quad w_y = \frac{1-\beta}{E_n} \quad (6)$$

其中 n_y 为类别 y 的样本数， $\beta \in [0, 1)$ （本研究取 $\beta = 0.9999$ ）。

- ② **WeightedRandomSampler 重采样**：引入 WeightedRandomSampler，为每个样本 i 分配采样权重 w_i ，使得少数类在每个 epoch 内的采样频次得到补偿：

$$w_i = \frac{1}{n_{y_i}^\alpha}, \quad \alpha \in [0, 1] \quad (7)$$

超参数 α 控制重采样的激进程度： $\alpha = 0$ 为纯均匀采样， $\alpha = 1$ 为完全反比采样。

③ **焦点损失**：舰船分类的难点在于，不同船只往往共享相似的低频水动力噪声，仅在极其微弱的特定机械线谱上存在差异。FocalLoss 类在 `train.py` 中作为内部类定义其核心是在标准交叉熵损失上乘以一个调制因子 $(1-p_t)^\gamma$ ，动态降低易分样本（ $p_t \rightarrow 1$ ）的损失贡献权重，将训练梯度集中在那些微弱且容易混淆的“困难声纹”

$$FL(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t) \quad (8)$$

④ **对数几率调整**：由于训练集分布极度倾斜，模型在推断时天然倾向于输出高频类别。LA 策略在模型训练的每次前向传播中，对模型输出的原始 Logit 向量 $f(x)$ 中直接加入对训练先验分布 π_y 的对数补偿项，使得预测决策向少数类倾斜：

$$\hat{y} = \arg \max_y [f_y(x) + \tau \log \pi_y] \quad (9)$$

先验 $\log \pi_y$ 在训练开始时一次性从统计的训练集类别频率中计算得出，并固定不变。在每次前向传播中，若对应的 `apply_logit_adj_in_train / apply_logit_adj_in_eval` 开关开启，则将其叠加到模型输出上

⑤ **应对噪声标签软化的标签平滑**（Label Smoothing）：考虑到真实水下录音中，某些 5 秒切片可能几乎只包含海浪声而无明显舰船信号（即“弱标签”状态）。强制模型对此类切片输出 100% 的绝对置信度（One-hot）会引发严重的过拟合。标签平滑是一种轻量化的正则化技术，将原始硬标签（one-hot 向量）中概率为 1 的位置“软化”到 $1-\epsilon$ ，并将剩余的 ϵ 均匀分配到其他类别。这抑制了网络对训练集产生过于绝对的置信度输出：

$$y_{smooth} = (1 - \epsilon) \cdot y_{hard} + \frac{\epsilon}{K} \quad (10)$$

2.4 对比实验与消融研究执行阶段

2.4.1 实验基础设施：自动化消融框架

为验证前述模型设计与数据处理策略的有效性，本研究围绕“模型结构优化—

类别不平衡处理—数据预处理策略”三个层面构建了一套系统性的对比实验与消融实验体系。由于 DeepShip 数据集规模较小且类别分布严重不均衡，单次实验结果容易受到随机因素影响，因此本研究通过逐步递进的实验设计，对各关键技术模块的贡献进行独立验证。

首先，在模型结构层面，通过基础网络核心组件消融实验 (M1-M5) 对轻量化骨干网络、注意力机制及非对称卷积等结构改进进行逐步验证，分析不同架构设计对舰船水声分类性能的影响，从而确定适合水声频谱特征的最优网络结构。

其次，在类别不平衡问题方面，针对 DeepShip 数据集中 Cargo 与 Tug 类占绝对多数的现实情况，引入 Logit Adjustment 先验校正策略，并通过五折交叉验证系统比较 FF、FT、TF、TT 四种配置，以评估不同先验注入方式对模型泛化性能与统计稳定性的影响。

最后，在数据层面，通过多组数据预处理策略消融实验，对动态重叠切分、VAD 阈值设置以及样本均衡策略等关键预处理参数进行对比分析，以验证第一阶段所设计数据处理管线的合理性。

通过上述三个层次的实验，本研究逐步回答了以下三个核心问题：

- ① 在轻量化约束下，何种网络结构最适合提取舰船水声频谱特征；
- ② 在极度类别不平衡的数据分布下，如何通过训练策略提升模型稳定性；
- ③ 数据预处理策略对最终分类性能的影响程度如何。

该实验体系使得模型设计、训练策略与数据处理之间形成完整的因果验证链条从而确保最终提出的 MyNet 架构不仅在实验指标上取得提升，同时在方法论上具备充分的实验论证基础。

2.4.2 实验基础设施：自动化消融框架

所有实验均由自主开发的 `run_experiments.py` (单次运行) 与 `run_kfold.py` (K 折交叉验证) 两套脚本驱动，无需人工干预。核心设计是集中式实验注册表——每一个消融变体被定义为一条配置记录，脚本循环读取注册表，自动生成对应的 YAML 配置文件并以子进程调用 `train.py` 完成训练，训练结束后解析 `results.txt` 并实时追加到汇总 CSV 文件中。

2.4.3 注意力部署位置深度 (Pre-DW vs Post-DW)

在初步确定 CBAM 注意力有效的基础上，进一步对注意力的插入位置和覆盖阶段进行了精细的超参数搜索。其实验结论已在早期针对 CIFAR-10 进行的基准实验中得到充分验证。

从系统性对比实验中，形成了以下有价值的规律性认知：关于插入阶段的选择（Which Stage）：在 Stage 2 和 Stage 4 处插入（s24 配置）明显优于在高层 Stage 4、5 处插入（s45），也优于全面铺开（s2345）。

这与卷积神经网络的特征层次结构相吻合：Stage 2 和 Stage 4 是网络中执行空间降采样的关键节点，特征图在此处完成从局部纹理到语义抽象的跨越，注意力在此处介入能对特征流过滤产生最大的影响力；而过高层（Stage 5 以后）的特征图分辨率已极低，空间注意力作用空间有限，且易引入过参数化问题。

关于插入位置的选择（Pre-DW vs Post-DW）：Pre-DW 在同等阶段配置下系统性优于 Post-DW（例如 preDW_s24 准确率 0.8725 > postDW_s4 准确率 0.8686）。语义解释上，Pre-DW 在深度卷积执行特征聚合之前先完成通道/空间筛选，能够以更低的噪声特征送入深度卷积，使后续逐通道提取聚焦于有效信息；而 Post-DW 则相当于对已经卷积完成的混合特征再做“亡羊补牢式”的再加权，在信息已充分融合后介入效果受限。

最终，CONFIG_CBAM_S24（Pre-DW CBAM, Stage 2 + Stage 4）作为最优注意力部署方案被固定为此后系列实验的标准骨干结构。

2.4.4 基础网络核心组件消融

实验设计原则：采用单变量控制法，在基础超参数完全相同的条件下（Focal Loss、学习率 1e-3、无采样器、关闭 LA），仅改变网络架构组件

表 2.3 消融基础网络核心组件实验内容

实验代号	架构说明	关键改变点
M1_BasicCNN	基础 CNN	关闭所有残差连接
M2_MobileNetV2	标准 MobileNetV2	开启残差连接，无任何注意力

M3_MobileNetV2_SE	MobileNetV2 + SE 注意力	在所有 Stage 叠加 Squeeze-Excitation
M4_MobileNetV2_CBAM	MobileNetV2 + Pre-DW CBAM	在 Stage 2、4 插入 CBAM
M5_Plus_LogitAdj	M4 架构 + 非对称卷积 + Logit Adj	额外开启 asymmetric=True、multiscale=True、交叉熵 + LA(TT)

表 2.4 基础网络核心组件消融实验结果

Experiment	Best Acc	Best F1	Sampler	Alpha	CE/FL	LA Train/Eval	Tau
M1_BasicC NN	0.64	0.6	OFF	0.5	FOCAL	F/F	1
M2_Mobile NetV2	0.64	0.6	OFF	0.5	FOCAL	F/F	1
M3_Mobile NetV2_SE	0.55	0.53	OFF	0.5	FOCAL	F/F	1
M4_Mobile NetV2_CB AM	0.45	0.45	OFF	0.5	FOCAL	F/F	1
M5_Plus_L ogitAdj	0.73	0.71	OFF	0.5	CE	T/T	1

从已记录的实验结果可以整理出以下关键观察：

- ① M1 (纯 CNN, 无残差) 与 M2 (标准 MobileNetV2) 在相同条件下 Val Acc 和 Val F1 完全相同 (Acc=0.6364, F1=0.5963), 说明在当前数据量规模下残差连接对分类能力的直接贡献有限, 起到的主要作用是加速收敛而非提升上限。
- ② M3 (全局 SE 注意力) 性能反而出现小幅下滑 (Acc=0.5455, F1=0.5315), 提示在所有阶段无差别铺设注意力会引入冗余的监督噪声, 轻量骨干网络在高维监督信号面前容量不足, 导致“注意力过拟合”。
- ③ M4 (CBAM 精准插入 Stage 2、4) 继续下滑 (Acc=0.4545, F1=0.4497), 尤其值得注意的是, 在不配合 Logit Adjustment 的条件下, CBAM 注意力机制对于这一类别极度不平衡的音频数据集效果并不理想——模型的注意力权重被多数类主导, 反

而损害了少数类的辨别力。

④ M5 (M4 + 非对称卷积 + 多尺度 + Logit Adj T/T) 取得了显著的性能跃升 (Acc=0.7273, F1=0.7090), 验证了注意力机制只有在配合有效的类别不平衡校正策略的前提下, 才能充分发挥其特征增强价值。

重要结论: 网络架构改进与数据不平衡问题必须协同解决, 单独引入注意力机制并不能自动解决标签偏斜问题, 反而可能因注意力权重被头部类主导而产生负面效果。

2.4.5 Logit Adjustment 策略的五折交叉验证分析

DeepShip 数据集经过文件级分层划分后, 冻结测试集仅包含 13 个原始录音文件, 验证集每折约 9~12 个文件。如此小型的评估集使得单次实验的 F1 指标受随机因素影响极大, 方差极高, 单次实验的结论缺乏统计可信度。

表 2.5 LA 消融实验定义

策略代号	训练时 LA	评估时 LA	含义
FF	✗	✗	纯 CE 基线, 无任何先验校正
FT	✗	✓	仅推断时做后处理先验补偿
TF	✓	✗	仅训练时以先验惩罚引导梯度更新
TT	✓	✓	训练与推断均施加先验校正

为此, 专门开发了 run_kfold.py 脚本, 对每个 LA 配置分别以 3 个独立随机种子 (42、43、44) 各运行 5 折, 总计 15 次独立训练, 对 test_file_f1 的均值和标准差进行稳健估计。

表 2.6 LA 消融实验结果

LA 策略	Test File F1 均值	Test File F1 标准差	结论
M5_LA_FF	0.57	0.11	基线最弱

M5_LA_FT	0.57	0.1	略低于 FF，推断后处理单独使用效果有限
M5_LA_TF	0.6	0.09	均值最优+方差最小→推荐选用
M5_LA_TT	0.6	0.13	均值略高但方差显著偏大

核心发现: TF 与 TT 策略的均值 F1 差异仅为 0.0019(可忽略不计), 但 TF 的标准差 (0.0942) 显著低于 TT (0.1339, 高出约 42%)。从统计稳健性角度, 标准差缩窄本身就具备重要的工程价值: 在小型测试集环境下, 更低的方差意味着模型性能对特定数据划分的敏感度更低, 实际部署时预期效果更稳定可靠。

特别值得关注的是 FT 策略 (仅推断时注入先验) 的表现甚至略低于 FF 基线 ($0.5698 < 0.5736$)。这说明: 在未经对应先验调整训练的模型上, 评估时强行叠加先验惩罚会破坏模型内部已经隐式学到的类别决策边界, 形成"训练分布与推断分布不匹配"的负迁移效应。因此, LA 的先验校正必须在训练阶段同步引入, 才能使模型在学习阶段就将先验补偿纳入梯度更新, 评估阶段再移除则等同于让模型以"经过先验增强训练后的原始 Logit"作最终决策, 从统计意义上是更为自治的选择。

基于上述分析, M5_LA_TF 被确立为后续所有实验的默认配置基线。

2.4.6 数据预处理策略消融实验

前三条消融实验集中于模型侧的架构设计, 而数据侧的预处理参数对最终性能同样具有决定性影响。该实验为系统评估第一阶段中各预处理决策的实际贡献。所有实验共享完全相同的训练配置基线: M5 架构, 唯一变量是输入数据的预处理版本, 从而做到对数据预处理方案的纯净评估, 排除模型因素的干扰。为增强结果的统计可信度, 每个数据版本均以 3 个不同随机种子 (42、43、44) 分别训练, 以均值和标准差评估稳定性。

表 2.7 数据预处理策略消融实验说明

版本代号	data_version 标识	核心预处理配置差异
B0	ds5s_v0	默认参数: RMS 阈值 0.005, 各类重叠率约 0.85/0.96/0.94, 启用片段级下采样
D1	ds5s_ol060_070_060	更低的重叠率 (0.60 / 0.70 / 0.60), 切片更稀疏, 减少相邻片段间的冗余信息
D4	ds5s_no_undersample	关闭片段级均衡下采样, 保留原始不平衡分布, 改以 CE 类别权重补偿, 测试纯权重方式对比
D5	ds5s_cap20perfile	每个原始音频文件最多保留 20 个切片, 限制单文件过度采样, 测试切片多样性影响
D6	ds5s_vad003	更严格的 VAD 阈值 (RMS 阈值提高至 0.03), 过滤更多弱信号片段, 测试更激进的静音剔除
D7	ds5s_vad008	最严格的 VAD 阈值 (RMS 阈值提高至 0.08), 保留最强能量片段, 测试极端过滤的效果

表 2.8 数据预处理策略消融实验结果

实验	数据版本	Val F1 均值	Test File F1 均值	Test File Acc 均值
B0_TopKVote	ds5s_v0	0.6	0.61	0.62

(基线)				
D1_TopKVote	ds5s_ol060_070_060	0.78	0.5	0.54
D4_TopKVote	ds5s_no_undersample	0.62	0.54	0.54
D5_TopKVote	ds5s_cap20perfile	0.84	0.38	0.41
D6_TopKVote	ds5s_vad003	0.6	0.61	0.62
D7_TopKVote	ds5s_vad008	0.6	0.61	0.62

从已记录的实验结果可以整理出以下关键观察

① D1 (降低重叠率)：验证集虚高，泛化能力下降。验证集 F1 均值 (0.7753) 显著高于基线，但测试集 F1 均值 (0.4950) 却低于基线，呈现出典型的验证集过优化/测试集泛化差的矛盾现象。原因在于较低的重叠率降低了数据量，导致训练集覆盖的声学多样性不足。

② D4 (关闭下采样, 改用 CE 权重)：效果次优且不稳定。关闭片段级均衡下采样后训练集中恢复原始的多数类数量优势，仅靠 CE 类别权重在损失层面补偿不平衡问题，测试集 F1 均值 (0.5368) 低于基线，表明在样本采样层面的均衡化对本任务而言依然不可或缺。

③ D5 (每文件切片数上限 20)：验证集严重虚高，测试集崩溃。Val F1 均值高达 0.8387，但 Test File F1 均值仅 0.3819——差距之大提示存在严重的验证过拟合。每文件上限 20 片导致长录音文件被大量截断，使得验证集切片的分布与真实测试切片分布产生显著偏差，验证集指标失去可信度。

④ D6/D7 (更严格的 VAD 过滤)：与基线 B0 完全一致。三个种子下 D6 和 D7 的所有指标与 B0 逐位相同，说明在基线 RMS 阈值 0.005 基础上继续提高过滤强度 (至 0.03 或 0.08) 并不会筛除更多有意义的弱信号片段——即在当前数据集中，绝大多数切片的能量均远高于 0.005 这一阈值，更高的 VAD 阈值是多余的，不会改变有效片段集合的构成。

综合结论：基线数据版本 ds5s_v0 在测试集上取得了最稳定的泛化性能。过度的数据稀疏化 (低重叠率 D1)、过度的每文件切片限制 (D5) 均带来了测试集性能的明显下滑。这一消融结果校验并支持了第一阶段数据预处理设计决策的合理性，确认基线数据版本为后续所有模型实验的标准数据输入。

3 后期拟完成的研究工作及进度安排

3.1 后期拟完成的研究工作

后续工作将依次进行进一步提升模型各项指标,探索面向 MCU 部署的模型缩放策略 (Model Scaling) 与开展基于 Grad-CAM 技术的模型可解释性可视化分析,并同步推进毕业论文的撰写与统稿。

3.1.1 引入知识蒸馏以提升模型指标

目前模型在测试集上表现出的严重的性能瓶颈,为进一步提升模型在测试集上的准确率,下阶段将会尝试引入知识蒸馏 (Knowledge Distillation) 机制以解决轻量化模型容量不足导致特征提取能力受限,无法从少量且不均衡的数据中提取到有效特征的问题。

本研究将训练一个高容量的强基线模型 (Audio Spectrogram Transformer) 作为教师模型。通过软标签 (Soft Targets) 指导当前的 MyNet 进行训练,同时尝试引入在大型公开图像数据集 (如 ImageNet) 上预训练的权重来初始化 MyNet 骨干网络与进行多折模型集成,以达成不增加最终边缘端推理计算量的前提下,大幅提升轻量化模型的泛化能力与分类精度的目的。

3.1.2 借鉴 EfficientNet 探索面向 MCU 部署的策略

本项目将借鉴 EfficientNet 的复合缩放思想,协同调整网络的深度、宽度与输入分辨率,开发出满足不同 MCU 硬件资源约束的系列化模型 (如 MyNet-S/M/L),并绘制准确率与计算量 (FLOPs/Params) 的权衡曲线。

3.1.3 基于 Grad-CAM 的可解释性分析

本项目将引入梯度加权类激活映射技术,将模型对各类舰船辐射噪声的关注区域可视化,验证注意力机制是否切实有效的聚焦于关键的线谱或螺旋桨节律特征,增强对模型注意力机制效果的透明度与学术说服力。

3.2 进度安排

具体进度安排如下：

2022 年 3 月 5 日——2022 年 4 月 5 日：完成知识蒸馏管线的搭建与教师模型的训练；引入迁移学习预训练权重；实施多折模型集成并进行超参数微调，确保模型核心评价指标（F1-Score 与 Accuracy）达到预期水平。

2022 年 4 月 6 日——2022 年 4 月 25 日：开展核心架构的模型缩放（Model Scaling）实验，统计各尺寸版本在 MCU 约束下的计算量与参数量；完成基于 Grad-CAM 的模型热力图生成与物理机理比对分析。

2022 年 4 月 26 日——2022 年 5 月 15 日：全面整理所有实验数据与对比图表；完成毕业论文各章节的撰写，梳理研究逻辑，并根据指导教师反馈对论文进行多轮修改与润色；完善格式排版，完成查重与最终定稿，准备提交所有项目工程代码及归档文件。

2022 年 5 月 16 日——2022 年 6 月 1 日：制作毕业答辩 PPT，提炼核心创新点与实验成果，进行模拟答辩演练，准备结题答辩。

4 存在的困难及解决方案

4.1 存在的困难

- ① **极端类别不平衡与数据稀缺限制模型性能上限**：尽管前期已采用 Logit Adjustment 先验校正和焦点损失（Focal Loss）策略在一定程度上缓解了 DeepShip 数据集的类别不平衡问题，但部分少数类的绝对样本量依然匮乏。轻量化网络本身容量有限，在小规模数据集上极易陷入局部最优或发生过拟合，导致当前模型在测试集上的泛化能力与 F1 指标遭遇瓶颈。
- ② **面向 MCU 部署的极致轻量化与精度维持存在矛盾**：实际应用场景要求模型最终部署在算力、内存和功耗均极其受限的 AUV 边缘微控制器（MCU）上。在后续进行极致的模型缩放（Model Scaling）时，随着网络深度和宽度的进一步物理压缩，模型的特征提取能力将不可避免地受损，可能出现最小尺寸模型精度下降过大、不达预期的风险。
- ③ **水声特征热力图的可解释性分析难度较大**：不同于直观的计算机视觉图像，梅尔频谱图反映的是抽象的时频能量分布。使用 Grad-CAM 生成的热力图可能存在背景噪声的干扰激活，准确将其高响应区域与物理意义上的螺旋桨节律、机械线谱等特定舰船声学机理对应起来，存在一定跨专业门槛。

4.2 解决方案

针对目前存在的问题和困难，提出以下解决方案：

- ① **针对数据与性能瓶颈**：全面引入知识蒸馏（Knowledge Distillation）与跨域迁移学习（Transfer Learning）。首先利用 ImageNet 预训练权重初始化 MyNet，赋予其成熟的底层纹理感知能力；其次，训练一个高容量的强基线模型作为“教师”，通过软标签（Soft Targets）指导“学生” MyNet 的特征学习。此外，在推断阶段实施多折模型集成（Ensemble），以此在不增加单次边缘端推理计算量的前提下，最大化地拔高分类精度上限。
- ② **针对模型缩放与资源矛盾**：摒弃单一维度的盲目裁剪，借鉴 EfficientNet 的复合缩放思想，在输入分辨率、网络深度和通道宽度三个维度系统性地寻找最优的联合

缩放系数。若最小化模型仍难以完全贴合极端的 MCU 硬件限制，将在结论中明确指出当前架构的局限性，并规划引入训练后量化（Post-Training Quantization, 如缩减至 INT8）或结构化剪枝（Pruning）作为本课题的自然延伸与补充手段。

③ **针对可解释性分析的挑战：**在进行 Grad-CAM 可视化分析时，严格结合先验的声学物理知识（如水动力噪声、机械噪声和螺旋桨噪声的典型频率范围）。采用按类别进行批量热力图统计平均的策略，抑制偶然噪声，提取出共性的高频或低频激活带，以增强模型可解释性论证的客观性与严谨性。

5 论文按时完成的可能性

本课题目前已经完成了开发环境搭建、DeepShip 复杂多源水声数据的清洗与全流程预处理管线构建。同时,已成功设计并实现了基于倒置残差与注意力机制的 MyNet 轻量化网络,并系统性地完成了基础组件(M1-M5 变体)、预处理参数以及 Logit Adjustment 策略的交叉验证与消融实验,确立了当前具备优良权衡特征的最优基线架构。

目前正在进行提分策略的代码实现与超参数调优,将要进行面向 MCU 的模型多维度复合缩放实验(Model Scaling)以及基于 Grad-CAM 的声学特征可视化分析,并同步推进毕业论文各章节的撰写论述。

综上所述,本项目前期数据基础扎实,核心算法管线均已跑通,后续优化方案目标明确且技术可行。研究进度完全符合既定的时间节点规划,存在的潜在技术困难均已制定了详尽的应对预案。论文能够按期在结题答辩前完成撰写与定稿,并取得具备一定工程参考价值的研究成果。