

哈爾濱工業大學(深圳)

毕业设计（论文）开题报告

题 目：基于轻量化卷积神经网络与注意力机制的水下舰船声学分类研究

专 业 通信工程

学 生 陈浩宇

学 号 220210229

指导教师 李维教授

日 期 2025 年 10 月 14 日

哈尔滨工业大学（深圳）教务处制

目 录

1 课题来源及研究的目的和意义	1
1.1 课题来源	1
1.2 研究目的与意义	1
2 国内外在该方向的研究现状及分析	2
2.1 舰船声学特征的研究	2
2.2 基于 AUV 的 MCU 的水下声学目标识别研究进展	3
2.3 数据稀缺问题与公开基准数据集	4
3 主要研究内容与研究方案	5
3.1 主要研究内容	5
3.2 研究方案	5
3.2.1 基础配置	5
3.2.2 设计模块化 Mobilenet 模型	5
3.2.3 注意力机制验证与模型可解释性	6
3.2.4 数据驱动的结构探索与面向 MCU 部署	8
4 进度安排，预期达到的目标	8
4.1 进度安排	8
4.2 预期研究目标与成果	8
5 课题已具备和所需的条件、经费	9
5.1 已具备的条件	9
5.2 所需的条件、经费	9
6 研究过程中可能遇到的困难和问题，解决的措施	10
7 主要参考文献	10

1 课题来源及研究的目的和意义

1.1 课题来源

本课题源于水下声学目标识别 (UATR) 在海洋探索、航道安全、生态保护等领域的迫切应用需求。^[1] 传统方法依赖人工判读或高消耗算法, 难以适应低成本、大规模、无人化的边缘设备部署场景。随着深度学习与物联网 (IoT) 技术融合, 智能计算正向资源受限的边缘平台 (如声呐浮标、AUV) 迁移。然而, 主流深度神经网络 (DNN) 模型的高复杂度与边缘设备的有限算力、内存、功耗存在巨大矛盾。^[2] 因此, 本课题聚焦于核心挑战, 旨在研究一种可高效部署于边缘设备的水下声学目标分类算法。

1.2 研究目的与意义

舰船在水下辐射的噪声一般会携带暗示其型号, 身份, 具体工况的“声纹”信息。对这些声纹进行精准分类是水下态势感知、反潜作战及国防安全保障的关键。自主水下航行器 (AUV) 凭借其高隐蔽性、持久续航与低成本优势, 已成为部署分布式水下监听网络、实现前沿持续侦察的理想平台。然而, 水声目标识别本身便是一项国际公认的难题。海洋声场环境时变空变的特性、不均匀的海水介质、信道畸变与混响, 以及各类环境噪声的干扰, 常常导致目标信号的特征被掩盖, 为提取鲁棒的声学特征带来了巨大挑战。^[3] 本研究旨在设计并实现一种专为边缘设备优化的轻量化卷积神经网络 (CNN) 模型, 以期在保证高分类精度的同时, 显著降低模型复杂度和资源消耗。具体研究内容如下:

- **设计轻量化网络架构:** 基于 MobileNetV2, 设计一个灵活可配的自定义网络 (MyNet)。
- **集成与优化注意力机制:** 将卷积块注意力模块 (CBAM) 融入 MyNet 架构, 通过实验探究其对水声信号关键特征辨识能力的提升效果, 并找到最优融合策略。
- **实现面向部署的模型缩放:** 为进行硬件平台的部署, 设计并实施一套模型缩放方案, 通过协同调整网络宽度、深度等维度, 调试多个不同资源消耗的模型。

2 国内外在该方向的研究现状及分析

2.1 舰船声学特征的研究

舰船辐射噪声主要由三种不同性质的声源构成：水动力噪声、机械噪声和螺旋桨噪声，这三种噪声互相影响作用。三种噪声在总辐射噪声中的相对贡献度，与舰船的设计水平、航行速度以及具体的作业状态息息相关^[4]。三种噪声可以由下表解释：

表 1: 舰船辐射噪声源、机理及主要频段总结

噪声类型	主要特征	典型频率范围
水动力噪声	强纯音及谐波	中高频
机械噪声	稳定低频线谱族	< 500 Hz
螺旋桨噪声	叶频及其谐波线谱	低频

目前学界主要的提取特征的方法有以下几种。对于低频，窄带线谱成分的分析与记录，LOFAR 是最经典的方法，其本质为短时傅里叶变换（STFT）的连续应用。对于螺旋桨噪声的检测，DEMON 可以解调出隐藏在宽带噪声中的低频节律信息。^[5]然而这类传统的水声目标识别方法在很大程度上依赖于专家知识，需要通过人工设计的算法来提取预定义的特征（如在 LOFAR 谱上手动圈出线谱）。

由于水听器接收到的原始信号是时间序列数据，若直接将其作为神经网络的输入，对于时长较长、采样率较高的信号，会产生巨大的计算负担，且难以有效捕捉信号在频域上的稳定特征^[6]，目前主流的深度学习舰船声学分类工具均采用了，将一维的时域声学信号转换为二维的图像化表示的数据预处理策略。通过短时傅里叶变换（Short-Time Fourier Transform, STFT），可以将一维时域信号分解，生成展示信号频率成分随时间变化的二维时频谱图^[7]在多种时频谱图中，梅尔频谱图（Mel Spectrogram）因其优越的性能而被广泛采用。其中梅尔刻度是一种模拟人耳对声音频率感知特性的非线性频率尺度，对低频部分的分辨率更高，对高频部分的分辨率较低。通过将声学信号转换为二维梅尔频谱图，其不仅能够压缩数据，还能突出与人类听觉感知更相关的关键频段特征，是一种极为有效的输入表示^[8]。这一预处理步骤的普及，使得研究人员能够直接将在计算机视觉领域取得巨大成功并已高度成熟的 CNN 架构。

2.2 基于 AUV 的 MCU 的水下声学目标识别研究进展

在将卷积神经网络应用到舰船声学分类的发展早期，有研究将多种不同的谱图（如 LOFAR 谱、DEMON 谱等）输入 AlexNet 进行分类，发现不同的谱图表示对识别性能有显著影响，其中 LOFAR 谱图展现出了最高的识别率，证明了输入特征表示与网络架构的匹配至关重要^[9]。随后，结构更深、性能更强的 VGG 网络也被应用于该领域。VGG 网络通过堆叠小的卷积核来构建深度模型，具有强大的特征提取能力。研究针对其网络参数进行了适应性修改，使其能够更好地处理水声信号谱图的特征^[9]，进一步提升了对舰船声学分类性能。随着网络深度的增加，梯度消失问题逐渐显现。为使得构建更深、更强大的网络成为可能，研究人员提出了倒置残差结构。^[10] ResNet 的核心思想是引入“残差连接”，允许信息跨层流动。将其应用于舰船声学分类，研究发现 ResNet 往往能取得比 AlexNet 和 VGG 更稳定和优越的结果，尤其是在处理复杂背景噪声和多变信道条件下的信号时，表现出更强的鲁棒性。

尽管 AlexNet、VGG 和 ResNet 等大型深度网络在分类精度上表现出色，但它们巨大的参数量和高昂的计算成本，使其难以部署在资源受限的边缘计算设备上，如自主水下航行器（AUV）、声呐浮标或水下传感器网络节点。这些平台通常对功耗、内存和计算能力有着严格的限制。因此，设计兼顾性能与效率的轻量化网络架构，已成为 UATR 领域一个至关重要的研究前沿。而其中 MobileNet 系列是轻量化设计的杰出代表，其核心创新在于深度可分离卷积和倒置残差结构。^[10] 深度可分离卷积将标准卷积分解为深度卷积和点卷积，大幅降低了计算量；倒置残差结构则设计了高效的“扩张-卷积-压缩”模式，并利用线性瓶颈层保留了丰富的特征信息，实现了卓越的效率与性能平衡。^[11]

在复杂的海洋环境中，舰船辐射噪声谱图中的关键判别性信息（如微弱的线谱特征或特定的谐波结构）可能仅占整个谱图的一小部分，而大部分区域则是背景噪声或不相关的干扰。注意力机制是一种模仿人类视觉，帮助神经网络聚焦于关键信息，同时抑制无关干扰的算法模块。主流的注意力机制有高效通道注意力（ECA-Net）与本文将要用到的 SE 和 CBAM。Squeeze-and-Excitation (SE) 注意力机制通过“Squeeze”（压缩）操作聚合全局空间信息，再通过“Excitation”（激励）操作学习各个通道的权重，SE 模块能够自适应地重新校准通道的特征响应，增强有用特征通道的权重，抑制无效通道^{[12][13]} SE 模块嵌入到 CNN 中，可以有效提升模型对不同类型舰船声学特征的敏感度。卷积块注意力模块（CBAM）则在 SE 注意力基础上进行了扩展，其依次应用通道注意力和空间注意力两个子模块，不仅关

注哪些通道重要，还通过空间注意力模块定位哪些区域重要。^[14] 对于谐波结构至关重要的频谱图分析，CBAM 被认为比单一的 SE 更具优势。

水下声学目标识别(UATR)因信道复杂、信噪比低而极具挑战性。^[2] 深度学习为此领域带来了突破，许多研究采用标准 CNN 处理频谱图并取得不错效果。公开的 ShipsEar 数据集包含了真实环境下的多种船舶辐射噪声，已成为该领域广泛使用的基准。^[15] 此外，注意力机制的应用不仅能提升模型精度，还能通过可视化注意力图谱，帮助研究人员理解模型的决策依据，即模型在对特定舰船进行分类时，究竟关注了谱图的哪些时频区域，这为提升模型的透明度和可解释性提供了重要途径^[16]。然而，当前研究多侧重于提升精度，鲜有将先进轻量化架构（如 MobileNetV2）、全面注意力机制（如 CBAM）与明确的 MCU 级部署目标系统性结合的研究，本课题旨在填补这一空白。

2.3 数据稀缺问题与公开基准数据集

深度学习模型是数据驱动的，其性能在很大程度上依赖于训练数据的数量和质量。然而，在水下声学领域，获取大规模、多样化且带有精确标注的舰船辐射噪声数据极其困难。数据的采集不仅成本高昂、耗时费力，而且由于涉及商业或军事敏感信息，大量数据为私有或保密状态，无法公开共享。这种公共数据集的严重匮乏，极大地阻碍了算法的公平比较和领域内研究成果的可复现性，是制约该领域发展的首要瓶颈。为缓解这一问题，学术界发布了若干公开数据集，它们已成为评估和比较不同算法性能的通用基准。其中，应用最广泛的两个数据集是 ShipsEar 和 DeepShip。

- **ShipsEar 数据集：**由西班牙维戈大学于 2016 年发布，是该领域最早被广泛使用的公开数据集之一^[15,17]。它包含了在西班牙大西洋沿岸真实浅海环境中录制的 90 段音频，涵盖 11 种不同类型的船只，并伴有丰富的环境和录制参数元数据。由于是在真实、复杂的海洋环境中录制，ShipsEar 数据包含大量的背景噪声，对算法的鲁棒性构成了很好的考验。
- **DeepShip 数据集：**于 2021 年发布，是目前规模较大的公开数据集^[18]。它包含了在加拿大温哥华港附近繁忙航道录制的超过 47 小时的音频，涉及 265 艘不同船只，归属于 4 个主要类别。DeepShip 数据集在数据量、船只多样性和录制时长上都远超 ShipsEar，为训练更深、更复杂的模型提供了宝贵资源，已迅速成为新的重要基准。

对这两个数据集的重度依赖，在推动领域标准化的同时也带来了一定的风险，即

模型可能对这两个特定地理位置的声学环境产生“过拟合”，而在其他海域泛化能力下降。这也凸显了未来构建更多样化、跨地域公开数据集的迫切性。此外，为应对数据不足的挑战，数据增强技术也备受关注，例如使用生成对抗网络（GAN）来合成新的、逼真的舰船噪声样本，以扩充有限的训练集。

3 主要研究内容与研究方案

3.1 主要研究内容

本研究的核心目标是，面向 AUV 等边缘计算平台，研发一种高效、轻量化的舰船声学目标分类模型。舰船辐射噪声并非均匀的随机信号，而是由水动力噪声、机械噪声和螺旋桨噪声等多种声源叠加而成，各自在时频谱上表现为独特的线谱、谐波和节律性特征。传统识别方法如 LOFAR 和 DEMON 虽能捕获部分特征，但其严重依赖专家知识进行人工特征提取，无法满足自动化、智能化部署的需求。相比之下，基于深度学习的方法，特别是卷积神经网络（CNN），能够从数据中自动学习这些关键的声学指纹。故本研究方案将首先立足于舰船声学机理的分析，将原始声学信号转换为富含信息的梅尔频谱图，再以此为基础，系统地开展后续研究。为确保更精准、更高效地捕获频谱图中的关键物理特征，缓解 AUV 上识别准确度与计算资源消耗之间的矛盾，本方案又提出了一系列的轻量化 CNN 模型设计、注意力机制的融合优化、非对称卷积的探索与模型缩放策略。

3.2 研究方案

3.2.1 基础配置

- **开发框架与语言：**基于 PyTorch 框架，使用 Python 3.9 开发。
- **工作流模式：**采用“本地开发调试 + 云端训练评估”的混合策略。本地使用 PyCharm + Anaconda 进行代码编写与调试，云端 Google Colab 平台利用其 T4 GPU 资源进行大规模训练。
- **代码与版本管理：**使用 Git 进行版本控制。

3.2.2 设计模块化 Mobilenet 模型

研究设计并实现一个名为 MyNet 的自定义轻量化 CNN。研究将以 MobileNetV2 的倒置残差块为核心单元，并遵循“配置驱动”原则进行模型的模块化设计，网络

的宏观架构均通过外部 YAML 文件定义，实现代码逻辑与网络结构的解耦，以支持不同架构对于船舶声分类快速实验迭代。

```

1 model_conf:
2   architecture:
3     - type: ConvBNReLU
4       params:
5         in_channels: 3
6         out_channels: 32
7         kernel_size: 3
8         stride: 1
9     - type: InvertedResidual
10      params:
11        in_channels: 32
12        out_channels: 64
13        stride: 1
14        expand_ratio: 6
15        attention_mode: post_dw
16     - type: ConvBNReLU
17       params:
18         in_channels: 64
19         out_channels: 32
20         kernel_size: 3
21         stride: 1
22     - type: CBAM
23       params:
24         in_channels: 32
25         ratio: 16
26         kernel_size: 7
27     - type: AdaptiveAvgPool2d
28       params:
29         output_size:
30           - 1
31           - 1
32     - type: Flatten
33       params: {}
34     ....

```

Listing 1: 模型网络结构 YAML 配置示例

3.2.3 注意力机制验证与模型可解释性

研究将 CBAM 注意力模块集成到 MyNet 架构中。利用 MyNet 的模块化设计，灵活地将 CBAM 插入到倒置残差块的不同位置。消融实验是通过逐一“移除”模型中的某个模块或组件，来验证该部分对模型整体性能贡献度的方法的验证方法，是主流的验证方法^[19]。通过消融实验，探究不同融合策略对模型进行船舶声分类性能的影响，以找到一个得以平衡性能与效率的最优模型结构。消融实验的原理可由下式表示：

$$\Delta_C = \text{Performance}(M_{\text{full}}) - \text{Performance}(M_{\text{without C}}) \quad (1)$$

消融实验具体方案如下：

模型评估指标：模型的评估主要通过以下两类指标进行：

表 2: 消融实验设计

实验 ID	基础架构	残差连接	注意力模块
M1	基础 CNN (仅深度卷积)	否	无
M2	MobileNetV2 模块	是	无
M3	MobileNetV2 模块	是	SE 模块
M4	MobileNetV2 模块	是	CBAM 模块
M5	MobileNetV2 模块	是	CBAM + 非对称卷积

- **模型分类性能指标:** 用于衡量模型对数据进行正确分类的能力。设 TP (True Positive) 为真正例, TN (True Negative) 为真负例, FP (False Positive) 为假正例, FN (False Negative) 为假负例。各指标计算公式如下^[20]:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2)$$

$$\text{Precision} = \frac{TP}{TP + FP} \quad (3)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (4)$$

$$\text{F1-Score} = \frac{2TP}{2TP + FP + FN} \quad (5)$$

- **模型复杂度指标:** 用于衡量模型的规模和计算效率。

参数量 (Parameters): 模型中所有需要学习的参数的总数量, 衡量模型的大小。

计算量 (FLOPs): 浮点运算次数 (Floating Point Operations), 衡量模型进行一次前向传播所需的计算成本。

本研究为深入理解模型的工作原理, 并验证 CBAM 注意力机制是否真正聚焦于船舶声信号的关键区域, 将引入基于 Grad-CAM (梯度加权类激活映射) 的可视化技术,。通过将 Grad-CAM 生成的热力图叠加在输入的梅尔频谱图上, 以直观地展示出模型在做出特定分类决策时, 其“注意力”集中在频谱图中的时频区域。研究将对比分析添加 CBAM 前后的模型热力图, 以量化和可视化地证明注意力机制在提升模型性能与可解释性方面的作用。Grad-CAM 原理可由下列式子表示^[21]:

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k} \quad (6)$$

$$L_{\text{raw}}^c = \sum_k \alpha_k^c A^k \quad (7)$$

$$L_{\text{Grad-CAM}}^c = \text{ReLU}(L_{\text{raw}}^c) \quad (8)$$

最后汇总并可视化所有实验数据，将最终优化的 MyNet 系列模型与 ResNet-SE 基线进行深入比较。研究将分析混淆矩阵，为特定部署场景推荐最优模型。

3.2.4 数据驱动的结构探索与面向 MCU 部署

非对称卷积核能更有效且更准确地捕获某些船舶声频谱上的特征，许多研究已经证实了这一点，例如 ACNet。^[22] 研究将探索 ShipsEar 数据集中船舶噪声的特殊谐波结构，研究使用非对称卷积核替代部分传统对称卷积核，实现更具针对性的高效特征提取。为适应收取船舶声的 AUV 上的 MCU 的有限资源，本研究将借鉴 EfficientNet 的复合缩放思想^[23]，设计并实施一套系统的模型缩放方案，并最终通过图像对比清晰展现各模型差异与优势区间，为特定硬件约束下的模型选择提供决策依据。

4 进度安排，预期达到的目标

4.1 进度安排

本项目将严格按照任务书规定的时间节点推进：

- **第一阶段（开题检查前：2025 年 10 月）：**深入文献调研，系统学习轻量化网络、注意力机制及水下声学识别技术。搭建好本地与云端的开发训练环境。完成开题报告的撰写。
- **第二阶段（开题至中期前：2025 年 10 月 2026 年 2 月）：**完成 ShipsEar 数据集的完整预处理流程。复现并评估 ResNet-SE 强基线模型，建立性能参照。完成 MyNet 系列模型的代码实现。系统性地开展核心消融实验（M1-M5），找到最优架构配置。
- **第三阶段（中期至结题前：2026 年 2 月 2026 年 4 月）：**基于最优架构，完成模型缩放实验并绘制性能-资源权衡曲线。完成 Grad-CAM 可视化分析。整理全部实验数据与结果，完成毕业论文的撰写、修改与定稿。准备毕业答辩。

4.2 预期研究目标与成果

本研究的核心目标是，面向 AUV 等边缘计算平台，研发一种高效、轻量化的舰船声学目标分类模型。为实现该目标，设定以下具体研究任务和预期成果：

- **设计一个适用于水声频谱图的轻量化分类模型：**研究将设计并实现一个名为 MyNet 的轻量化卷积神经网络，其结构将为处理舰船噪声的频谱图特征进行

优化。最终目标是在保证分类性能的同时，模型足够小巧、计算足够迅速。

- **在公开数据集上验证模型的有效性与先进性：**研究将在公开的 ShipsEar 数据集上进行充分实验。通过引入注意力机制等优化手段，使最终模型的分类准确率能够达到甚至超过经典的 ResNet-SE 等更为复杂的基线模型，而模型的参数量和计算量要显著低于这些基线，体现其轻量化优势。
- **解释模型如何识别不同舰船的声音：**研究将利用 Grad-CAM 等可视化技术，直观地分析模型在判断舰船类别时，究竟是“听”了声音频谱中的哪些关键频段（如螺旋桨噪声、机械噪声等），以此来验证模型决策的合理性。
- **为实际部署提供一系列可选方案：**研究将探索一套有效的模型缩放策略。最终产出一系列“大、中、小”不同尺寸的模型版本，并分析它们在“分类精度-资源消耗”上的表现，确保至少有一个版本能在典型的微控制器（MCU）硬件上运行。

本研究的最终成果将以以下形式呈现：

- 一份详细阐述上述研究过程、实验结果与结论的毕业设计论文。
- 一套包含模型代码、训练脚本、配置文件及预训练权重的项目工程文件，以保证研究结果的可复现性。

5 课题已具备和所需的条件、经费

5.1 已具备的条件

- **硬件条件：**个人计算机（NVIDIA RTX 3050 Ti 4GB），Google Colab 云平台。
- **软件条件：**Python 3.9、Anaconda、PyCharm、PyTorch 及相关科学计算库。
- **数据基础：**ShipsEar 数据集
- **知识储备：**掌握深度学习、CNN、信号处理等基础理论知识，具备编程实践能力。

5.2 所需的条件、经费

无经费需求。

6 研究过程中可能遇到的困难和问题，解决的措施

- **困难 1：模型过拟合。**
 - **原因：**模型容量相对数据集过大。
 - **措施：**采取组合策略：应用权重衰减、Dropout 等标准正则化技术；实施数据增强。
- **困难 2：模型训练不收敛或效果不佳。**
 - **原因：**引入复杂结构时可能出现梯度问题或超参数不当。
 - **措施：**使用 Kaiming 初始化保证权重初始化得当；尝试更先进的学习率调度策略，如余弦退火；更换优化器；并仔细检查数据归一化流程。
- **困难 3：模型缩放后性能与资源不达预期。**
 - **原因：**最小模型可能仍超出 MCU 承载范围，或精度下降过大。
 - **措施：**在结论中明确指出当前架构的局限性，并提出未来工作方向，如训练后量化（Post-Training Quantization）或剪枝（Pruning），作为本课题的自然延伸进行规划。

7 主要参考文献

- [1] 李孝峰. 基于卷积神经网络的小样本水下目标识别研究[D]. [S.l.]: 哈尔滨工程大学, 2022.
- [2] Han X C, Ren C, Wang L, et al. Underwater acoustic target recognition method based on a joint neural network[J/OL]. PLOS ONE, 2022, 17(4): 1-15. <https://doi.org/10.1371/journal.pone.0266425>.
- [3] 邓晋, 潘安迪, 肖川, et al. 基于迁移学习的水声目标识别[J/OL]. 计算机系统应用, 2020, 29(10): 255-261. <http://dx.doi.org/10.15888/j.cnki.csa.007538>.
- [4] 袁常乐, 万德成. 不同几何形状水下远场噪声分析[C] // 第三十一届全国水动力学研讨会暨第十六届全国水动力学学术会议文集. 2020: 440-447.
- [5] 潘丁宁, 胡长青, 赵梅, et al. 船舶辐射噪声 DEMON 线谱相位差特征提取[J/OL]. 声学技术, 2025, 44(2): 171-180. <http://dx.doi.org/10.16300/j.cnki.1000-3630.23110201>.
- [6] 张奇, 笪良龙, 王超, 等. 基于深度学习的水声被动目标识别研究综述[J/OL]. 电子与信息学报, 2023, 45(11): 4190-4202. <http://dx.doi.org/10.11999/JEIT221301>.
- [7] Chu H-C, Zhang Y-L, Chiang H-C. A CNN Sound Classification Mechanism Using

- Data Augmentation[J/OL]. *Sensors*, 2023, 23(15) : 6972. <http://dx.doi.org/10.3390/s23156972>.
- [8] Yan C, Yan S, Yao T, et al. A Lightweight Network Based on Multi-Scale Asymmetric Convolutional Neural Networks with Attention Mechanism for Ship-Radiated Noise Classification[J]. *Journal of Marine Science and Engineering*, 2024, 12(1) : 130.
 - [9] Lin X, Dong R, Lv Z. Deep Learning-Based Classification of Raw Hydroacoustic Signal: A Review[J/OL]. *Journal of Marine Science and Engineering*, 2023, 11(1). <https://www.mdpi.com/2077-1312/11/1/3>.
 - [10] Sandler M, Howard A, Zhu M, et al. MobileNetV2: Inverted Residuals and Linear Bottlenecks[C/OL] // *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2018 : 4510-4520. <https://arxiv.org/abs/1801.04381>.
 - [11] 韩宇. 基于注意力机制和倒置残差模块的目标检测算法研究[D]. [S.l.] : 山东师范大学, 2024.
 - [12] 赵晓晓. 基于 YOLOv10n+SE 注意力机制的车辆车牌检测[J/OL]. *信息与电脑*, 2025, 37(10) : 6-8. <http://dx.doi.org/CNKI:SUN:XXDL.0.2025-10-002>.
 - [13] Hu J, Shen L, Sun G. Squeeze-and-Excitation Networks[C/OL] // *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2018 : 7132-7141. <http://dx.doi.org/10.1109/CVPR.2018.00745>.
 - [14] Woo S, Park J, Lee J-Y, et al. CBAM: Convolutional Block Attention Module[C/OL] // *Proceedings of the European Conference on Computer Vision (ECCV)*. 2018 : 3-19. http://dx.doi.org/10.1007/978-3-030-01234-2_1.
 - [15] Santos-Domínguez D, Torres-Guijarro S, Cardenal-López A, et al. ShipsEar: An underwater vessel noise database[J/OL]. *Applied Acoustics*, 2016, 113 : 64-69. <https://www.sciencedirect.com/science/article/pii/S0003682X16301566>.
 - [16] Xiao X, Wang W, Ren Q, et al. Underwater acoustic target recognition using attention-based deep neural network[J]. *JASA Express Letters*, 2021, 1(10) : 106001.
 - [17] Santos-Domínguez D, Torres-Guijarro S, Cardenal-López A, et al. ShipsEar: An underwater vessel noise database[J]. *Applied Acoustics*, 2016, 113 : 64-69.
 - [18] Irfan M, Zheng J, Ali S, et al. DeepShip: An underwater acoustic benchmark dataset and a separable convolution based autoencoder for classification[J]. *Expert Systems with Applications*, 2021, 183 : 115270.
 - [19] 周斌. 改进的 YOLOv8 算法在建筑外立面检测中的应用[J/OL]. *测绘地理信息*,

: 1-10. <http://dx.doi.org/10.14188/j.2095-6045.20240662>.

- [20] 周志华. 机器学习[M]. 北京: 清华大学出版社, 2016.
- [21] 姬忠远, 张晶晶, 刘泽昊, et al. 基于卷积神经网络的稀疏 SAR 目标梯度加权类激活映射分类方法 (英文) [J/OL]. Transactions of Nanjing University of Aeronautics and Astronautics, 2025, 42(04): 525-540. <http://dx.doi.org/10.16356/j.1005-1120.2025.04.008>.
- [22] Ding X, Guo Y, Ding G, et al. ACNet: Strengthening the Kernel Skeletons for Powerful CNN via Asymmetric Convolution Blocks[C/OL] // 2019 IEEE/CVF International Conference on Computer Vision (ICCV). 2019: 1911-1920. <http://dx.doi.org/10.1109/ICCV.2019.00200>.
- [23] 余华东, 邓庆安, 商俊杰. 基于 EfficientNet 网络的蜜蜂识别跟踪计数系统[J/OL]. 安徽电气工程职业技术学院学报, 2025, 30(03): 89-98. <http://dx.doi.org/CNKI:SUN:ADZD.0.2025-03-013>.